

## תרגיל בית 1 – מבוא ללמידה חישובית

מגיש: נתן בלוך

Linear Algebra

### שאלה 1.

נדרש להוכיח את הטענה הבאה:

*A symmetric matrix A is PSD if and only if it can be written as  $A = X X^T$*

ואכן, **בכיוון הראשון**,  $\Leftarrow$ , נניח כי  $A = X X^T$ . אכן A הינה סימטרית, שכן מתקיים –

$$A^T = (X X^T)^T = (X^T)^T X^T = X X^T = A$$

כמו כן, נרצה להראות שלכל וקטור  $v$  מתקיים  $v^T A v \geq 0$ . יהי וקטור  $v$ . נסמן ראשית –

$$y := X^T \cdot v \in \mathbb{R}^{n \times 1}$$

ובעת, מתקיים –

$$v^T A v = v^T X X^T v = (X^T v)^T (X^T v) = y^T y \geq 0$$

כאשר, האי-שיוויון האחרון מתקיים לכל וקטור  $y$ , שכן בעצם זה נובע מכך שאם נסמן  $y = (y_1, \dots, y_n)$ , נקבל

$$y^T y = \sum_{i=1}^n y_i \cdot y_i = \sum_{i=1}^n y_i^2 \geq 0$$

כנדרש בעצם, שכן הראנו כי לכל וקטור  $v$  מתקיים  $v^T A v \geq 0$ , ולכן A הינה מטריצה סימטרית מוגדרת חיובית.

**בכיוון השני**,  $\Rightarrow$ , נניח כי המטריצה A הינה מטריצה סימטרית המוגדרת חיובית. כיוון ש-A מוגדרת חיובית, ניתן להסיק כי כל הערכים העצמיים שלה הינם אי-שליליים, כלומר לכל ערך עצמי  $\lambda$ , מתקיים ש- $\lambda \geq 0$ . ניתן לראות זאת בקלות שאם נסמן ב- $u$  וקטור עצמי של A עם ערך עצמי  $\lambda$ , כלומר  $Au = \lambda u$ . מכאן נקבל כי –

$$u^T A u = u^T \lambda u = \lambda u^T u$$

מצד שני, מההנחה כי A הינה מוגדרת חיובית, לכל וקטור  $v$  מתקיים  $v^T A v \geq 0$ .

על כן, נסיק כי בפרט עבור הוקטור  $u$  מתקיים ש- $\lambda u^T u \geq 0$ , וכיוון ש- $u^T u \geq 0$ , מנימוקים קודמים, נסיק כי מתקיים גם כן  $\lambda \geq 0$ . על כן, הנ"ל מוכיח כי כל הערכים העצמיים של A הינם אי-שליליים.

כעת, על ידי שימוש ברמז, וכן שימוש בפירוק (*decomposition*) של מטריצות סימטריות מוגדרות חיובית, ניתן

לכתוב את המטריצה A באופן הבא –  $A = Q^T D Q$ , כאשר Q מטריצה אורתוגונלית, וכן D מטריצה

אלכסונית, כך שבאלכסון מופיעים כל הערכים העצמיים של A. לכן, ממה שהוכחנו עד כה, מתקיים ש-

$D_{ii} \geq 0$  לכל  $i$ . על כן, ניתן להגדיר את המטריצה האלכסונית B באופן הבא –  $B_{ii} = \sqrt{D_{ii}}$ , וכן לכל  $i \neq j$ ,

מתקיים  $B_{ij} = 0$  וכך נקבל שמתקיים  $D = B^2$ . כמו כן, B אלכסונית, ולכן סימטרית, ומתקיים  $B = B^T$ .

כעת נסתכל השיוויון –

$$A = Q^T D Q \stackrel{D=B^2}{=} Q^T B^2 Q \stackrel{B=B^T}{=} Q^T B^T B Q = (BQ)^T BQ$$

על כן, בחירה של המטריצה X, באופן הבא –  $X = (BQ)^T$ , תשיג את הנדרש, שכן יתקיים –

$$X X^T = (BQ)^T ((BQ)^T)^T = (BQ)^T BQ = A$$

כנדרש בכיוון זה של הטענה.

**בסה"כ, הוכחנו את שני כיווני הטענה כנדרש.**

## שאלה 2.

יהיו  $A, B$  מטריצות ממשיות סימטריות המוגדרות חיובית, וכן יהי סקלר  $0 \leq \theta \leq 1$ . נדרש להראות כי המטריצה  $\theta A + (1 - \theta)B$  הינה מטריצה ממשית סימטרית המוגדרת חיובית. ואכן, מההנחות מתקיים כי –

$$A = A^T, B = B^T$$

ולכן אם נסמן את המטריצה  $C = \theta A + (1 - \theta)B$ , נקבל כי מתקיים –

$$C^T = (\theta A + (1 - \theta)B)^T = (\theta A)^T + ((1 - \theta)B)^T = \theta A^T + (1 - \theta)B^T = \theta A + (1 - \theta)B = C$$

כאשר הנ"ל מוכיח את הסימטריות. כמו כן, נדרש להראות כי המטריצה הנ"ל הינה מוגדרת חיובית.

מהנחה, מתקיים **לכל** וקטור  $v$  –

$$v^T A v \geq 0, v^T B v \geq 0$$

כמו כן, מכיוון ש- $0 \leq \theta \leq 1$ , מתקיים כי  $0 \leq \theta, 1 - \theta$  ולכן ניתן לקבל מכאן –

$$v^T C v = v^T (\theta A + (1 - \theta)B) v = \underbrace{\theta}_{\geq 0} \cdot \underbrace{v^T A v}_{\geq 0 \forall v} + \underbrace{(1 - \theta)}_{\geq 0} \cdot \underbrace{v^T B v}_{\geq 0 \forall v} \geq 0$$

ומכאן, ניתן להסיק כי המטריצה  $\theta A + (1 - \theta)B$  הינה מוגדרת חיובית וכן סימטרית, כנדרש.

## Calculus and Probability

### שאלה 1.

נגדיר את הנגזרת של סקלר  $y$  ביחס לוקטור  $x$  כוקטור עמודה המוגדר באופן הבא –

$$\left(\frac{\partial y}{\partial x}\right)_i = \frac{\partial y}{\partial x_i}$$

לכל  $i = 1, \dots, n$ . תהי  $A$  מטריצה מסדר  $n \times n$ . נדרש להוכיח כי מתקיים –

$$\frac{\partial x^T A x}{\partial x} = (A + A^T)x$$

ואכן, נסמן ראשית  $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$  וכן  $A = \begin{pmatrix} a_{1,1} & \cdots & a_{1,n} \\ \vdots & \ddots & \vdots \\ a_{n,1} & \cdots & a_{n,n} \end{pmatrix}$ . מכאן מתקיים ש-

$$\begin{aligned} x^T A x &= (x_1, \dots, x_n) \cdot \begin{pmatrix} \sum_{j=1}^n a_{1,j} \cdot x_j \\ \vdots \\ \sum_{j=1}^n a_{n,j} \cdot x_j \end{pmatrix} = \sum_{i=1}^n x_i \cdot \left( \sum_{j=1}^n a_{i,j} \cdot x_j \right) \\ \Rightarrow x^T A x &= \sum_{i=1}^n \sum_{j=1}^n a_{i,j} x_i x_j \end{aligned}$$

על מנת להוכיח את השיוויון הנדרש, נראה שמתקיים שיוויון עבור כל קורדיאנטה. יהי  $k \in \{1, \dots, n\}$ . נרצה להראות כי מתקיים –

$$\left(\frac{\partial x^T A x}{\partial x}\right)_k = ((A + A^T)x)_k$$

ואכן מתקיים לפי הגדרה,

$$\begin{aligned} \left(\frac{\partial x^T A x}{\partial x}\right)_k &= \frac{\partial x^T A x}{\partial x_k} = \frac{\partial \left(\sum_{i=1}^n \sum_{j=1}^n a_{i,j} x_i x_j\right)}{\partial x_k} = \frac{\sum_{i=1}^n \sum_{j=1}^n \frac{\partial (a_{i,j} x_i x_j)}{\partial x_k}}{\partial x_k} = \\ &= \underbrace{2 \cdot a_{k,k} x_k}_{\text{case of } i=j=k} + \underbrace{\sum_{k \neq j \geq 1} a_{k,j} x_j}_{\text{case of } i=k, j \neq k} + \underbrace{\sum_{k \neq i \geq 1} a_{i,k} x_i}_{\text{case of } j=k, i \neq k} = \sum_{j=1}^n a_{k,j} x_j + \sum_{i=1}^n a_{i,k} x_i = \\ &= (Ax)_k + (A^T x)_k = ((A + A^T)x)_k \end{aligned}$$

כאשר, נבחין שעבור המקרים בהם  $i \neq k, j \neq k$ , בעת גזירה לפי המשתנה  $x_k$ , מדובר באיברים קבועים מהצורה  $a_{i,j} x_i x_j$ , ולכן נגזרתם לפי  $x_k$  הינה 0. מכאן, ניתן להסיק כאמור כי מתקיים השיוויון הדרוש –

$$\frac{\partial x^T A x}{\partial x} = (A + A^T)x$$

שכן הוכחנו כי השיוויון מתקיים לכל קואורדינטה, כנדרש.

## שאלה 2.

נתון  $\mathbf{p} = (p_1, \dots, p_n)$  התפלגות דיסקרטית, כאשר מתקיים  $\sum_{i=1}^n p_i = 1$  וכן  $p_i \geq 0$  לכל  $i$ . נתונה גם –

$$H(\mathbf{p}) = - \sum_{i=1}^n p_i \cdot \log(p_i)$$

נראה באמצעות כופלי לגרנד' כי עבור ההתפלגות האחידה, מקבלים אנטרופיה מקסימלית. לשם כך, נגדיר את הפונקציה הבאה, לפי האילוץ הנתון –

$$g_1(\mathbf{p}) = \sum_{i=1}^n p_i - 1$$

וכעת נגדיר פונק' חדשה באופן הבא –

$$h(\mathbf{p}, \lambda_1) = H(\mathbf{p}) + \lambda_1 g_1(\mathbf{p}) = - \sum_{i=1}^n p_i \cdot \log(p_i) + \lambda_1 \sum_{i=1}^n p_i - \lambda_1$$

כעת, נרצה לגזור לפי כל אחד מהמשתנים ולהראות כי המקסימום מתקבל עבור  $p_1 = \dots = p_n = \frac{1}{n}$ .

נגזור ראשית לפי  $p_i$ , ונקבל –

$$\begin{aligned} \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial p_i} &= \frac{\partial(-\sum_{i=1}^n p_i \cdot \log(p_i) + \lambda_1 \sum_{i=1}^n p_i - \lambda_1)}{\partial p_i} = \\ &= -\left(p_i \cdot \frac{1}{p_i} + 1 \cdot \log(p_i)\right) + \lambda_1 = -\log(p_i) + \lambda_1 - 1 \end{aligned}$$

כעת, נגזור לפי  $\lambda_1$ , ונקבל –

$$\begin{aligned} \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial \lambda_1} &= \frac{\partial(-\sum_{i=1}^n p_i \cdot \log(p_i) + \lambda_1 \sum_{i=1}^n p_i - \lambda_1)}{\partial \lambda_1} = \\ &= \sum_{i=1}^n p_i - 1 \end{aligned}$$

מכאן, נסיק כי מתקיים –

$$\nabla h(\mathbf{p}, \lambda_1) = \begin{pmatrix} \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial p_1} \\ \vdots \\ \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial p_n} \\ \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial \lambda_1} \end{pmatrix}$$

ואם נרצה למצוא את המקסימום, נחפש את הערכים עבורם  $\nabla h(\mathbf{p}, \lambda_1) = 0$ , ונקבל כי מתקיים –

$$\nabla h(\mathbf{p}, \lambda_1) = \begin{pmatrix} \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial p_1} \\ \vdots \\ \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial p_n} \\ \frac{\partial h(\mathbf{p}, \lambda_1)}{\partial \lambda_1} \end{pmatrix} = \begin{pmatrix} -\log(p_1) + \lambda_1 - 1 \\ \vdots \\ -\log(p_n) + \lambda_1 - 1 \\ \sum_{i=1}^n p_i - 1 \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$\Rightarrow \log(p_i) = \lambda_1 - 1 \quad \forall i \in \{1, \dots, n\} \Rightarrow \log(p_1) = \dots = \log(p_n) \Rightarrow p_1 = p_2 = \dots = p_n$$

ומכאן, נשתמש באילוץ האחרון, כדי לקבל את הרצוי –

$$\sum_{i=1}^n p_i - 1 = 0 \quad \Rightarrow \quad \sum_{i=1}^n p_i = 1 \quad \Rightarrow \quad n \cdot p_i = 1 \quad \Rightarrow \quad \mathbf{p_i} = \frac{\mathbf{1}}{\mathbf{n}}$$

ומכאן קיבלנו כי  $\mathbf{p} = (p_1, \dots, p_n) = (\frac{1}{n}, \dots, \frac{1}{n})$  כלומר  $\mathbf{p}$  הינה ההתפלגות אחידה.

### שאלה 3.

נתונים  $n$  משתנים מקריים חיוביים,  $X_0, \dots, X_{n-1}$ , שהינם בלתי תלויים, ומתפלגים זהה (כלומר  $i. i. d$ ). כמו כן, נתונה פונקציית התפלגות רציפה  $f_X$ .

### סעיף א.

נדרש להוכיח כי מתקיים השיויון הבא –

$$\mathbb{P}(X_0 \geq \max(X_1, X_2, \dots, X_n)) = \int_0^\infty (F_{X_0}(a))^{n-1} f_{X_0}(a) da$$

ואכן, על מנת להוכיח זאת, נשתמש בנוסחת ההסתברות השלמה, וכן נסתכל על  $\max(X_1, X_2, \dots, X_n)$  כמשתנה מקרי. נקבל כי –

$$\mathbb{P}(X_0 \geq \max(X_1, X_2, \dots, X_n)) = \int_0^\infty \mathbb{P}(\max(X_1, X_2, \dots, X_n) \leq a) \cdot f_{X_0}(a) da$$

כמו כן, מתקיים כי –

$$\begin{aligned} \mathbb{P}(\max(X_1, X_2, \dots, X_n) \leq a) &= \mathbb{P}(X_1 \leq a, X_2 \leq a, \dots, X_{n-1} \leq a) = \\ &= \mathbb{P}(X_1 \leq a) \cdot \mathbb{P}(X_2 \leq a) \cdots \mathbb{P}(X_{n-1} \leq a) = (\mathbb{P}(X_0 \leq a))^{n-1} = (F_{X_0}(a))^{n-1} \end{aligned}$$

כך שמתקיים בשה"כ השיויון הדרוש –

$$\mathbb{P}(X_0 \geq \max(X_1, X_2, \dots, X_n)) = \int_0^\infty (F_{X_0}(a))^{n-1} f_{X_0}(a) da$$

### סעיף ב.

ניזכר בכך שמתקיים –

$$F_{X_0}(a) = \int_{-\infty}^a f_{X_0}(t) dt \stackrel{X_i \geq 0}{=} \int_0^a f_{X_0}(t) dt$$

כך שלמעשה,  $F_{X_0}$  הינה הפונק' הקדומה של  $f_{X_0}$ . נסתכל על הפונקציה  $(F_{X_0}(a))^n$  ונגזור אותה כך שנקבל –

$$\left( (F_{X_0}(a))^n \right)' = n \cdot (F_{X_0}(a))^{n-1} \cdot f_{X_0}(a)$$

כעת, נשתמש בכך על מנת לפתור את האינטגרל הנתון, ונקבל –

$$\mathbb{P}(X_0 \geq \max(X_1, X_2, \dots, X_n)) = \int_0^\infty (F_{X_0}(a))^{n-1} f_{X_0}(a) da = \frac{1}{n} \cdot \int_0^\infty n (F_{X_0}(a))^{n-1} f_{X_0}(a) da$$

$$= \frac{1}{n} \cdot \int_0^\infty \left( (F_{X_0}(a))^n \right)' da = \frac{1}{n} \cdot \left( \underbrace{\lim_{x \rightarrow \infty} F_{X_0}(x)}_{=1 \text{ as } a \text{ CDF}} - \underbrace{F_{X_0}(0)}_{=0 \text{ as } X_i \geq 0} \right) = \frac{1}{n} \cdot (1 - 0) = \frac{1}{n}$$

כנדרש.

## .Decision Rules and Concentration Bounds

### שאלה 1.

יהיו  $X$  ו- $Y$  משתנים מקריים, כך ש- $Y \in \{1, 2, \dots, L\}$ . תהי  $\ell_{0-1}$  פונקציית ההפסד 0-1 שהוגדרה בביתה. נרצה להראות ש- $h = \arg \min_{f: \mathcal{X} \rightarrow \mathbb{R}} \mathbb{E}[\ell_{0-1}(f(X), Y)]$  נתונה על ידי –

$$h(x) = \arg \max_{i \in \{1, 2, \dots, L\}} \mathbb{P}[Y = i | X = x]$$

**פיתרון.** נניח כי  $X = x_0$  ובבצע את החישוב תחת התניה, על מנת להוכיח כי מתקיים –

$$h(x_0) = \arg \max_{i \in \{1, 2, \dots, L\}} \mathbb{P}[Y = i | X = x_0]$$

נסתכל על פונק' ההפסד הצפוי בפי שהוגדרה בביתה –

$$L(h) = \mathbb{E}[\ell_{0-1}(h(X), Y)] = \sum_{\substack{x \in \mathcal{X} \\ y \in \mathcal{Y}}} \mathbb{P}[X = x, Y = y] \cdot \ell_{0-1}(h(x), y)$$

ובאמור נרצה להביא למינימום את פונק' הזו. נרצה למצוא את הערך של  $h(x_0)$  המביא למינימום את פונק' ההפסד הצפוי  $L(h)$ . ואכן, נמשיך בחישובים ונקבל –

$$L(h) = \underbrace{\sum_{\substack{x \in \mathcal{X} \setminus \{x_0\} \\ y \in \mathcal{Y}}} \mathbb{P}[X = x, Y = y] \cdot \ell_{0-1}(h(x), y)}_{\substack{\text{doesn't depend on } x_0 \\ \Rightarrow \text{doesn't depend on } h(x_0)}} + \underbrace{\sum_{y \in \mathcal{Y}} \mathbb{P}[X = x_0, Y = y] \cdot \ell_{0-1}(h(x_0), y)}_{=: g_{x_0}(h)}$$

מכיוון שכעת הנחנו כי  $X = x_0$ , וכן אנו רוצים למצוא את הערך האופטימלי של  $h(x_0)$  המביא למינימום את פונק' ההפסד הצפוי  $L(h)$ , ניתן להתייחס רק לגורמים התלויים ב- $x_0$  בפונק' ההפסד, ולכן נרצה להביא למינימום את הגורמים הללו. נסמן ב- $g_{x_0}(h)$  את הגורמים שתלויים ב- $x_0$  בפונק' ההפסד, וכעת נבחין בתוצאות הללו –

$$\text{if } h(x_0) \notin \mathcal{Y} = \{1, 2, \dots, L\} \Rightarrow \forall y \in \mathcal{Y}. \ell_{0-1}(h(x_0), y) = 1$$

$$\Rightarrow g_{x_0}(h) = \sum_{y \in \mathcal{Y}} \mathbb{P}[X = x_0, Y = y] \cdot \underbrace{\ell_{0-1}(h(x_0), y)}_{=1} = \sum_{y \in \mathcal{Y}} \mathbb{P}[X = x_0, Y = y] = \mathbb{P}[X = x_0]$$

ובנוסף,

$$\text{if } h(x_0) = i \in \mathcal{Y} \Rightarrow \forall y \in \mathcal{Y} \setminus \{i\}. \ell_{0-1}(h(x_0), y) = 1 \text{ and } \ell_{0-1}(h(x_0), i) = 0$$

$$\Rightarrow g_{x_0}(h) = \sum_{y \in \mathcal{Y}} \mathbb{P}[X = x_0, Y = y] \cdot \ell_{0-1}(h(x_0), y) = \mathbb{P}[X = x_0] - \mathbb{P}[X = x_0, Y = i]$$

לכן, בעצם קיבלנו כי הגורם הנ"ל הינו –

$$g_{x_0}(h) = \begin{cases} \mathbb{P}[X = x_0] & \text{if } h(x_0) \notin \mathcal{Y} \\ \mathbb{P}[X = x_0] - \mathbb{P}[X = x_0, Y = i] & \text{o.w. } h(x_0) = i \in \mathcal{Y} \end{cases}$$

מכאן, ברור כי הגורם הנ"ל מגיע למינימום עבור  $h(x_0) \in \mathcal{Y}$ , שכן מתקיים –

$$\mathbb{P}[X = x_0] - \mathbb{P}[X = x_0, Y = i] \leq \mathbb{P}[X = x_0]$$

ובפרט,  $g_{x_0}(h)$  משיגה את המינימום שלה במקרה בו  $\mathbb{P}[X = x_0, Y = i]$  מקסימלי, ועל כן, נרצה לבחור את ה-*predictor* האופטימלי עבור  $x_0$  באופן הבא –

$$\begin{aligned} h(x_0) &= \arg \max_{i \in \{1, 2, \dots, L\}} \mathbb{P}[X = x_0, Y = i] = \\ &= \arg \max_{i \in \{1, 2, \dots, L\}} \mathbb{P}[Y = i | X = x_0] \cdot \underbrace{\mathbb{P}[X = x_0]}_{\substack{\text{const} \geq 0 \\ \text{for all } i}} = \\ &= \arg \max_{i \in \{1, 2, \dots, L\}} \mathbb{P}[Y = i | X = x_0] \end{aligned}$$

כנדרש.



## שאלה 2.

נתון  $X = (X_1, \dots, X_n)^T$  וקטור של משתנים מקריים. לפי ההגדרה, נרצה לחזות את  $y \in \mathcal{Y} = \{0,1\}$  באופן הבא –

$$y = \begin{cases} 1 & \text{if } \mathbb{P}[y = 1|X] > \mathbb{P}[y = 0|X] \\ 0 & \text{otherwise} \end{cases}$$

כאשר הסימון של  $\mathbb{P}[y = y | X]$  הינו סימון מקוצר ל-  $\mathbb{P}[y = y | X = x]$ . נתונים גם  $p = \mathbb{P}[y = 1]$ , ולכן ניתן להסיק כי  $p = \mathbb{P}[y = 1]$  ו-  $1 - p = \mathbb{P}[y = 0]$ . כמו כן, בהנתן  $y = i$ , פונק' הצפיפות של הוקטור  $X$  הינה  $f_i(X) = f(X, \mu_i, \Sigma)$ , כלומר למעשה  $X_{|y=i} \sim N(\mu_i, \Sigma)$ .

## סעיף א.

נתונה נקודה  $x \in \mathbb{R}^d$  ונדרש לבצע *labeling* של  $y$  לפיה. נדרש למצוא תנאי פשוט יותר על  $X$  כך שתתקיים שקילות ביניהם. נשתמש בכלל בייס עבור התפלגות רציפה –

$$\text{Continuous Bayes' rule: } f_X(x | Y = y) = \frac{\mathbb{P}[Y = y | X = x] \cdot f_X(x)}{\mathbb{P}[Y = y]}$$

ובעת, מתקיים –

$$\begin{aligned} & \mathbb{P}[y = 1|X = x] > \mathbb{P}[y = 0|X = x] \Leftrightarrow \\ & \Leftrightarrow \frac{f_X(x|Y = 1) \cdot \mathbb{P}[y = 1]}{f_X(x)} > \frac{f_X(x|Y = 0) \cdot \mathbb{P}[y = 0]}{f_X(x)} \Leftrightarrow \\ & \Leftrightarrow f_X(x|Y = 1) \cdot \mathbb{P}[y = 1] > f_X(x|Y = 0) \cdot \mathbb{P}[y = 0] \Leftrightarrow \\ & \Leftrightarrow \frac{f_X(x|Y = 1)}{f_X(x|Y = 0)} > \frac{\mathbb{P}[y = 0]}{\mathbb{P}[y = 1]} \Leftrightarrow \\ & \Leftrightarrow \frac{\frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_1)^T \Sigma^{-1}(x - \mu_1)\right)}{\frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_0)^T \Sigma^{-1}(x - \mu_0)\right)} > \frac{1-p}{p} \Leftrightarrow \\ & \Leftrightarrow \exp\left(-\frac{1}{2}(x - \mu_1)^T \Sigma^{-1}(x - \mu_1) - \left(-\frac{1}{2}(x - \mu_0)^T \Sigma^{-1}(x - \mu_0)\right)\right) > \frac{1-p}{p} \Leftrightarrow \\ & \Leftrightarrow -\frac{1}{2}(x - \mu_1)^T \Sigma^{-1}(x - \mu_1) + \frac{1}{2}(x - \mu_0)^T \Sigma^{-1}(x - \mu_0) > \ln\left(\frac{1-p}{p}\right) \Leftrightarrow \\ & \Leftrightarrow (x - \mu_0)^T \Sigma^{-1}(x - \mu_0) - (x - \mu_1)^T \Sigma^{-1}(x - \mu_1) > 2 \cdot \ln\left(\frac{1-p}{p}\right) \Leftrightarrow \\ & \Leftrightarrow (x^T \Sigma^{-1} - \mu_0^T \Sigma^{-1})(x - \mu_0) - (x^T \Sigma^{-1} - \mu_1^T \Sigma^{-1})(x - \mu_1) > 2 \cdot \ln\left(\frac{1-p}{p}\right) \Leftrightarrow \end{aligned}$$

$$\Leftrightarrow \quad \mathbf{x}^T \Sigma^{-1} \mathbf{x} - \mathbf{x}^T \Sigma^{-1} \mu_0 - \mu_0^T \Sigma^{-1} \mathbf{x} + \mu_0^T \Sigma^{-1} \mu_0 \quad (\text{continues})$$

$$- (\mathbf{x}^T \Sigma^{-1} \mathbf{x} - \mathbf{x}^T \Sigma^{-1} \mu_1 - \mu_1^T \Sigma^{-1} \mathbf{x} + \mu_1^T \Sigma^{-1} \mu_1) > 2 \cdot \ln\left(\frac{1-p}{p}\right) \Leftrightarrow$$

$$\Leftrightarrow -\mathbf{x}^T \Sigma^{-1} \mu_0 - \mu_0^T \Sigma^{-1} \mathbf{x} + \mu_0^T \Sigma^{-1} \mu_0 + \mathbf{x}^T \Sigma^{-1} \mu_1 + \mu_1^T \Sigma^{-1} \mathbf{x} - \mu_1^T \Sigma^{-1} \mu_1 > 2 \cdot \ln\left(\frac{1-p}{p}\right)$$

$$\Leftrightarrow -\mathbf{x}^T \Sigma^{-1} (\mu_0 - \mu_1) + (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > 2 \cdot \ln\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1$$

$$\Leftrightarrow \mathbf{x}^T \Sigma^{-1} (\mu_1 - \mu_0) + (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > 2 \cdot \ln\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1$$

כעת, נבחין כי מתקיים  $Cov(X, Y) = Cov(Y, X)$  שכן מדובר ביחס סימטרי, ולכן לכל  $i, j \in \{1, \dots, n\}$  מתקיים כי  $\Sigma_{i,j} = Cov(X_i, X_j) = Cov(X_j, X_i) = \Sigma_{j,i}$  - מכאן, ניתן להסיק כי המטריצה  $\Sigma^{-1}$  הינה סימטרית גם כן. לכן  $\Sigma^{-1} = (\Sigma^{-1})^T$ . כעת, מתקיים -

$$\mathbf{x}^T \Sigma^{-1} (\mu_1 - \mu_0) = \mathbf{x}^T (\Sigma^{-1})^T (\mu_1 - \mu_0) = (\Sigma^{-1} \mathbf{x})^T (\mu_1 - \mu_0) = ((\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x})^T$$

אך מכיוון ש-  $(\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} \in \mathbb{R}$ , למעשה, מתקיים כי -

$$((\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x})^T = (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x}$$

ולכן בעצם קיבלנו כי מתקיים -

$$\mathbf{x}^T \Sigma^{-1} (\mu_1 - \mu_0) = (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x}$$

מכאן, נמשיך את פישוט התנאי מהתנאי האחרון אליו הגענו -

$$\Leftrightarrow \underbrace{\mathbf{x}^T \Sigma^{-1} (\mu_1 - \mu_0)}_{=(\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x}} + (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > 2 \cdot \ln\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1$$

$$\Leftrightarrow 2(\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > 2 \cdot \ln\left(\frac{1-p}{p}\right) - \mu_0^T \Sigma^{-1} \mu_0 + \mu_1^T \Sigma^{-1} \mu_1$$

$$\Leftrightarrow (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > \ln\left(\frac{1-p}{p}\right) + \frac{\mu_1^T \Sigma^{-1} \mu_1}{2} - \frac{\mu_0^T \Sigma^{-1} \mu_0}{2}$$

וזוהו אם כך תנאי פשוט יותר על  $X = \mathbf{x}$  על מנת לבצע labeling של  $y$  לפיה. בסה"כ קיבלנו את התנאי -

$$y = 1 \quad \text{if and only if} \quad (\mu_1 - \mu_0)^T \Sigma^{-1} \mathbf{x} > \ln\left(\frac{1-p}{p}\right) + \frac{\mu_1^T \Sigma^{-1} \mu_1}{2} - \frac{\mu_0^T \Sigma^{-1} \mu_0}{2}$$

כנדרש בסעיף זה.

## סעיף ב.

גבול ההחלטה של הבעיה הזו מוגדר על ידי קבוצות הנקודות ב- $\mathbb{R}^d$  עבור מתקיים –

$$\mathbb{P}[y = 1|X = x] = \mathbb{P}[y = 0|X = x]$$

נבין את צורת ההחלטה עבור  $d > 1$  כללי, אך ראשית עבור אינטואיציה, נסתכל על  $d = 1, 2$ . לפי הסעיף הקודם, קיבלנו את התנאי השקול –

$$\begin{aligned} \mathbb{P}[y = 1|X = x] = \mathbb{P}[y = 0|X = x] &\Leftrightarrow \\ \Leftrightarrow (\mu_1 - \mu_0)^T \Sigma^{-1} x &= \ln\left(\frac{1-p}{p}\right) + \frac{\mu_1^T \Sigma^{-1} \mu_1}{2} - \frac{\mu_0^T \Sigma^{-1} \mu_0}{2} \end{aligned}$$

**עבור  $d = 1$** , מתקיים  $\Sigma = \text{Cov}(X_1, X_1) = \text{Var}(X_1) \Rightarrow \Sigma^{-1} = \frac{1}{\text{Var}(X_1)}$  כמו כן,  $\mu_1, \mu_0$  הם למעשה סקלרים, שכן מדובר בוקטורים באורך 1, ומכאן נקבל –

$$\begin{aligned} x &= \frac{\text{Var}(X_1)}{\mu_1 - \mu_0} \cdot \left( \ln\left(\frac{1-p}{p}\right) + \frac{\mu_1^2}{2 \cdot \text{Var}(X_1)} - \frac{\mu_0^2}{2 \cdot \text{Var}(X_1)} \right) = \\ &= \frac{\text{Var}(X_1)}{\mu_1 - \mu_0} \cdot \ln\left(\frac{1-p}{p}\right) + \frac{1}{2} \left( \frac{\mu_1^2 - \mu_0^2}{\mu_1 - \mu_0} \right) = \frac{\text{Var}(X_1)}{\mu_1 - \mu_0} \cdot \ln\left(\frac{1-p}{p}\right) + \frac{1}{2} (\mu_1 + \mu_0) \end{aligned}$$

ובמקרה זה  $x$  הינה נקודה על הישר, ובעצם מתקיים  $x$  הינה ממימד 0 בעוד מימד המרחב הינו  $d = 1$ .

**עבור  $d = 2$** , וכן ע"י סימון  $\theta_1 := \text{Var}(X_1), \theta_2 := \text{Var}(X_2)$  ו- $c = \text{Cov}(X_1, X_2)$ , מתקיים –

$$\begin{aligned} \Sigma &= \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) \end{pmatrix} = \begin{pmatrix} \sigma_1 & c \\ c & \sigma_2 \end{pmatrix} \Rightarrow \Sigma^{-1} = \begin{pmatrix} \frac{\sigma_2}{\sigma_1 \sigma_2 - c^2} & -\frac{c}{\sigma_1 \sigma_2 - c^2} \\ -\frac{c}{\sigma_1 \sigma_2 - c^2} & \frac{\sigma_1}{\sigma_1 \sigma_2 - c^2} \end{pmatrix} \\ &= a \ 2 \times 2 \text{ matrix of constants} \end{aligned}$$

כאשר זה נובע מכך ש- $\text{Var}(X_1), \text{Var}(X_2), \text{Cov}(X_1, X_2)$  הינם קבועים ביחס ל- $X = x$ , ותלויים רק בהתפלגות הרקע. על כן, אם נסתכל על השיוויון של גבול ההחלטה –

$$(\mu_1 - \mu_0)^T \Sigma^{-1} x = \ln\left(\frac{1-p}{p}\right) + \frac{\mu_1^T \Sigma^{-1} \mu_1}{2} - \frac{\mu_0^T \Sigma^{-1} \mu_0}{2}$$

ונזכור כי  $x \in \mathbb{R}^2$ , כלומר  $x = (x_1, x_2)$ , נקבל בעצם **משוואה לינארית בשני הנעלמים  $x_1, x_2$  בלבד**, שכן כפי שהוסבר שאר הגורמים בשיוויון זה הינם קבועים.

כלומר, התנאי מגדיר קו ישר במישור דו-מימדי, וכן הישר ממימד 1, ונמצא במרחב ממימד  $2 - \mathbb{R}^2$ .

**באופן כללי**, עבור  $d \in \mathbb{N}$ , ניתן להכליל ולהסיק כי התנאי  $\mathbb{P}[y = 1|X = x] = \mathbb{P}[y = 0|X = x]$  יוצר משוואה אחת עם  $d$  משתנים, מה שמגדיר תת-מרחב מגודל  $d - 1$  בתוך המרחב  $\mathbb{R}^d$  שמימדו הינו  $d$ . במילים אחרות, התנאי מגדיר מושג בשם "על-מישור" (*hyperplane*), שהוא למעשה תת-מרחב בגודל  $n - 1$  בתוך מרחב מגודל  $n$ .

### שאלה 3.

נתונים  $X_1, \dots, X_n$  משתנים מקרים בלתי תלויים המתפלגים באופן זהה ואחיד בקטע  $[-3, 5]$ . נגדיר את סכומם

$$S = X_1 + \dots + X_n$$

נדרש למצוא באמצעות אי-שיוויון הופדינג  $N \in \mathbb{N}$ , כך שלכל  $n \geq N$ , מתקיים –

$$\mathbb{P}[S > n^2 + 0.2n] < 0.1$$

**פיתרון.** ראשית נבדוק את התנאים הדרושים כדי להשתמש בחסם הופדינג. אכן נתון כי  $X_1, \dots, X_n$  בלתי תלויים. כמו כן, כיוון שהם מתפלגים אחיד על הקטע  $[-3, 5]$ , ניתן להסיק כי –

$$\mathbb{P}[-3 \leq X_i \leq 5] = 1 \quad \text{for every } i$$

כאשר במקרה זה נשתמש ב-  $a = -3, b = 5$ .  
כמו כן, מתקיים כי –

$$\mathbb{E}[X_i] \stackrel{\substack{\sim \\ \sim U(-3,5)}}{=} \frac{a+b}{2} = \frac{-3+5}{2} = 1$$

וכן, אם נסתכל על ממוצע המשתנים המקריים, ונסמנו  $\bar{X}$ , נזכור כי מתקיים  $\bar{X} = \frac{S}{n}$ . ומכאן –

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{X_1 + \dots + X_n}{n}\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \sum_{i=1}^n 1 = \frac{1}{n} \cdot (n \cdot 1) = 1$$

ובעת, נחשב –

$$\mathbb{P}[S > n^2 + 0.2n] = \mathbb{P}\left[\frac{S}{n} > n + 0.2\right] = \mathbb{P}[\bar{X} > n + 0.2] =$$

$$= \mathbb{P}[\bar{X} - 1 > n - 0.8] = \mathbb{P}[\bar{X} - \mathbb{E}[\bar{X}] > n - 0.8] \leq$$

$$\leq \mathbb{P}[\bar{X} - \mathbb{E}[\bar{X}] \geq n - 0.8] \leq \mathbb{P}[|\bar{X} - \mathbb{E}[\bar{X}]| \geq n - 0.8] \leq 2e^{-\frac{2n(n-0.8)^2}{(b-a)^2}}$$

ובאמור, המטרה הינה למצוא  $N \in \mathbb{N}$ , כך שלכל  $n \geq N$ , מתקיים –

$$\mathbb{P}[S > n^2 + 0.2n] \leq 2e^{-\frac{2n(n-0.8)^2}{(b-a)^2}} < 0.1$$

על כן, נפתור את אי-השוויון הימני על מנת להשיג את החסם הדרוש. מתקיים –

$$2e^{-\frac{2n(n-0.8)^2}{(b-a)^2}} < 0.1 \Leftrightarrow e^{-\frac{2n(n-0.8)^2}{(b-a)^2}} < 0.05 \Leftrightarrow -\frac{2n(n-0.8)^2}{(5-(-3))^2} < \ln(0.05) \Leftrightarrow$$

$$\Leftrightarrow n(n-0.8)^2 \geq -\ln(0.05) \cdot 32 \Leftrightarrow n(n-0.8)^2 \geq \ln(20) \cdot 32$$

ואכן, על ידי פתרון אי-שוויון זה (שהינו פולינום ב- $n$ ), נקבל כי האי-שוויון מתקיים עבור –

$$n \geq 5.12495$$

וביוון ש-  $n \in \mathbb{N}$ , נסיק כי למעשה לכל  $n \geq 6$ , מתקיים האי-שוויון –

$$\mathbb{P}[S > n^2 + 0.2n] < 0.1$$

כנדרש.

#### שאלה 4.

##### סעיף א.

נרצה לחשב את  $\mathbb{E}[R_i]$ . מתקיים כי  $R_i = \sum_{j=1}^n R_{ij}$ , ולכן נקבל –

$$\mathbb{E}[R_i] = \mathbb{E}\left[\sum_{j=1}^n R_{ij}\right] = \sum_{j=1}^n \mathbb{E}[R_{ij}]$$

ועל כן, נרצה לחשב לשם כך את  $\mathbb{E}[R_{ij}]$ . מהגדרת המשתנה המקרי  $R_{ij}$ , מתקיים –

$$R_{ij} = \begin{cases} L_j & \text{if server } i \text{ was assigned to job } j \\ 0 & \text{otherwise} \end{cases}$$

לפי ההנחה, לכל עבודה  $j$  ייבחר סרבר באופן אקראי, ולכן ניתן להסיק כי כל עבודה מתפלגת אחיד עם פרמטרים של  $U(1, m)$ , כאשר מדובר כאן בהתפלגות אחידה דיסקרטית. על כן –

$$\mathbb{P}[\text{server } i \text{ was assigned to job } j] = \frac{1}{m}$$

מכאן, מהגדרת התוחלת, נחשב את  $\mathbb{E}[R_{ij}]$  באופן הבא –

$$\begin{aligned} \mathbb{E}[R_{ij}] &= L_j \cdot \mathbb{P}[\text{server } i \text{ was assigned to job } j] + \\ &+ 0 \cdot (1 - \mathbb{P}[\text{server } i \text{ was assigned to job } j]) = L_j \cdot \frac{1}{m} \end{aligned}$$

ובעת, ניתן לחשב את  $\mathbb{E}[R_i]$  –

$$\mathbb{E}[R_i] = \sum_{j=1}^n \mathbb{E}[R_{ij}] = \sum_{j=1}^n L_j \cdot \frac{1}{m} = \frac{1}{m} \cdot \sum_{j=1}^n L_j = \frac{L}{m}$$

##### סעיף ב.

נשתמש ב-*Chernoff Multiplicative Bound* על מנת לחסום את הביטוי –

$$\mathbb{P}[R_i \geq (1 + \delta)\mathbb{E}[R_i]]$$

ראשית, נבחין כי אכן כל התנאים הדרושים מתקיימים. מתקיים כי –

$$R_i = R_{i1} + R_{i2} + \dots + R_{in}$$

$R_{i1}, R_{i2}, \dots, R_{in}$  are independent as the assignment of jobs to servers is random

מהנתונים מתקיים כי -  $0 \leq j \leq n$  לכל  $R_{ij} \in \{0, L_j\}$ ,  $0 \leq L_j \leq 1$

על כן, כל התנאים הדרושים מתקיימים ולכן ניתן להשתמש באי-שוויון זה עם  $\delta = 0.1$  ולקבל –

$$\mathbb{P}[R_i \geq (1 + \delta)\mathbb{E}[R_i]] \leq \left(\frac{e^\delta}{(1 + \delta)^{1+\delta}}\right)^{\frac{L}{m}} = (0.995170)^{\frac{L}{m}}$$

## סעיף ג.

נניח כי  $\delta = 0.1$ . נרצה למצוא חסם להסתברות כי לפחות אחד מהסרברים הינו עמוס ב- 10% יותר מאשר העומס הצפוי. כלומר, נרצה לחסום את ההסתברות הבאה –

$$\mathbb{P}[R_1 \geq (1 + \delta)\mathbb{E}[R_1] \text{ or } \dots \text{ or } R_m \geq (1 + \delta)\mathbb{E}[R_m]]$$

ניזכר ראשית בחסם האיחוד, ולפיו מתקיים –

$$\mathbb{P}[A_1 \cup \dots \cup A_k] \leq \sum_{i=1}^k \mathbb{P}[A_i]$$

על כן, לפי חסם האיחוד, ולפי סעיף ב' מתקיים –

$$\mathbb{P}[R_1 \geq (1 + \delta)\mathbb{E}[R_1] \text{ or } \dots \text{ or } R_m \geq (1 + \delta)\mathbb{E}[R_m]] \leq$$

$$\leq \sum_{i=1}^m \mathbb{P}[R_i \geq (1 + \delta)\mathbb{E}[R_i]] \stackrel{(b)}{\leq} \sum_{i=1}^m (0.995170)^{\frac{L}{m}} = m \cdot (0.995170)^{\frac{L}{m}}$$

## Programming Assignment

### שאלה 1.

#### סעיף א. הקוד –

```
main.py x
1 import numpy as np
2 from matplotlib import pyplot as plt
3 from collections import Counter
4 from scipy.spatial import distance
5 from sklearn.datasets import fetch_openml
6 mnist = fetch_openml('mnist_784')
7 data = mnist['data']
8 labels = mnist['target']
9
10 idx = np.random.RandomState(0).choice(70000, 11000)
11 train = data[idx[:10000], :].astype(int)
12 train_labels = labels[idx[:10000]]
13 test = data[idx[10000:], :].astype(int)
14 test_labels = labels[idx[10000:]]
15
16 # Pre-processing: Calculating distances between all test images and all train images. Done for efficiency reasons.
17 dists = distance.cdist(test, train)
18 # test_list variable is for inner use, for time-complexity issues.
19 test_list = list()
20 for i in range(0, len(test)):
21     test_list.append(list(test[i]))
22
23
24
25 # parameters: train_imgs - train images, train_labels - train labels, image_query - query image, k - integer parameter
26 def KNN(train_imgs, train_labels, image_query, k):
27     i = test_list.index(list(image_query)) # finds index of current image query
28     label_counter = Counter() # useful data structure to count labels
29     dists_i = [(dists[i][j], train_labels[j]) for j in range(len(train_imgs))] # distances of query img from data imgs
30     dists_i.sort(key=lambda tup: tup[0]) # sorting the distances
31     for j in range(k): # choosing k nearest (first k in sorted list)
32         label_counter[int(dists_i[j][1])] += 1 # counting labels of k nearest neighbors
33     return (label_counter.most_common(1))[0][0] # returns most common label among k nearest
34
```

## סעיף ב.

נריץ עם  $n = 1000$  התמונות הראשונות ב-*training images*, עם  $k = 10$ , על כל תמונה ב-*test images*.

## הקוד –

```
main.py x
36 # Section b
37 print("Section (b) runs: ")
38 n = 1000
39 k = 10
40 correct = 0
41 train_b = train[:n]
42 train_labels_b = train_labels[:n]
43 for i in range(0, n):
44     prediction = knn(train_b, train_labels_b, test[i], k)
45     if prediction == int(test_labels[i]):
46         correct += 1
47
48 print("\tCorrect =", correct, "/", n, "=", correct / n)
49 print("\tPercentage is", 100 * correct / n, "%.")
50 print("Section (b) done.")
51
```

## הפלט –

```
Section (b) runs:
    Correct = 858 / 1000 = 0.858
    Percentage is 85.8 %.
Section (b) done.
```

אחוז הדיוק הוא באמור 85.8%, שכן קיבלנו כי האלגוריתם דייק ב-858 מתוך 1000 התמונות ב-*test images*. על כן, הדיוק הינו –  $accuracy = 858 / 1000 = 0.858$ .

אילו ה-*predictor* היה מנבא תוצאות באופן אקראי, ניתן להסיק כי אחוז הדיוק היה באזור ה-10%, מכיוון שיש 10 תגיות (שכן  $Label\ Space = \{0,1,\dots,9\}$ ) שונות וההתפלגות למעשה במצב זה הייתה אחידה כתוצאה מהאקראיות של ה-*predictor*, ולכן ניתן להסיק שאחוז הדיוק בתוחלת היה 10%. כלומר במקרה זה –

$$\mathbb{E}[prediction\ accuracy] = 0.1$$



## סעיף ג.

בסעיף זה נחשב את ה-*prediction accuracy* כתלות ב- $k$ , הפרמטר המייצג את מספר השכנים לפיו ה-*predictor* מחליט על ה-*label*. נשרטט את הגרף המתקבל עבור  $k = 1, 2, 3, \dots, 100$ , וכן  $n = 1000$ .

## הקוד –


```
main.py x
52 # Section c
53 print("Section (c) runs: ")
54 n = 1000
55 train_c = train[:n]
56 train_labels_c = train_labels[:n]
57 x_labels = [i for i in range(1, 101)]          # x_labels[1,2,..., 100] to be used as k
58 y_labels = []
59 for k in x_labels:
60     predictions = np.zeros(len(test))
61     for i in range(len(test)):
62         predictions[i] = kNN(train_c, train_labels_c, test[i], k)
63     correct = np.sum(predictions == np.array(test_labels[:n], dtype=int))
64     y_labels.append(correct / n)
65
66 plt.plot(x_labels, y_labels)
67 plt.xlabel("k")
68 plt.ylabel("accuracy")
69 plt.show()
70
71 maximumC = max(y_labels)
72 index = y_labels.index(maximumC) + 1          # + 1 as i'th index represents k=i+1
73 print("The best k is", index, "with a value of", maximumC)
74 print("Section (c) done.")
75
```

## הפלט המתקבל –

```
Section (c) runs:
The best k is 4 with a value of 0.884
Section (c) done.
```

נבחין כי ה- $k$  הטוב ביותר מתקבל עבור  $k = 4$ , ובו מתקבל דיוק של  $accuracy = 0.884$ . המגמה העיקרית שנראית בשרטוט היא שעבור  $k$  הולך וגדל, מתקבל דיוק הולך ופוחת של האלגוריתם שמימשנו. ניתן להסביר מגמה זו על ידי כך שכאשר מסתכלים על מספר הולך וגדל של שכנים קרובים ביותר (כאשר  $k$  גדל), מסתכלים על שכנים שנמצאים במרחק הולך וגדל מהנקודה הנוכחית, ולכן ה-*label* שנקבע לפיהם נקבע גם על פי נקודות רחוקות יותר (באופן שבו המשקל של כל נקודה שווה), שלא בהכרח מנבאות באופן מיטבי את הנק' הנתונה.

## הגרף המתקבל –




במילים אחרות, כיוון שלכל נקודה באלגוריתם משקל שווה, ככל שנסתכל על מספר הולך וגדל של שכנים קרובים ביותר, בעצם נקבל החלטה לסיווג ה-*label* לפי מספר עולה של נקודות שנמצאות במרחקים הולכים וגדלים מהנקודה הנוכחית, ומכך שלכל נקודה ב- $k$  הקרובות ביותר משקל שווה, יתקבל *label* לפי נקודות (שהן תמונות) רחוקות יותר, ולכן התוצאות (הסיווגים ל-*labels*) המתקבלות טובות פחות ככל ש- $k$  גדל.

## סעיף ד.

בסעיף זה נחשב את ה-*prediction accuracy* כתלות ב- $n$ , כאשר נגדיר גם  $k = 1$ . נשרטט את הגרף המתקבל עבור  $n = 100, 200, \dots, 5000$ . הקוד –

```
main.py x
76 # Section d
77 print("Section (d) runs: ")
78 k = 1
79 x_labels = [n for n in range(100, 5001, 100)] # x_labels=[100,..., 5000] to be used as first n elems in train images
80 y_labels = []
81 for n in x_labels:
82     train_d = train[:n]
83     train_labels_d = train_labels[:n]
84     predictions = np.zeros(len(test))
85     for i in range(len(test)):
86         predictions[i] = KNN(train_d, train_labels_d, test[i], k)
87     correct = np.sum(predictions == np.array(test_labels, dtype=int))
88     y_labels.append(correct / 1000)
89
90
91 plt.plot(x_labels, y_labels)
92 plt.xlabel("n")
93 plt.ylabel("accuracy")
94 plt.show()
95 print("Section d done.")
96
```



הגרף המתקבל –

ניתן לראות את המגמה לפיה כאשר  $n$ , שמייצג את מספר תמונות האימון (*training images*) שלפיהם מבצעים את ה-*prediction*, גדל, גם אחוז הדיוק (ה-*accuracy*) בחיזוי ה-*label* גדל גם הוא. ניזכור כי במקרה זה  $k = 1$ , כלומר מחפשים את הנקודה (התמונה) הקרובה ביותר לתמונה שרוצים לחזות, ועל כן, ככל שנסתכל על מספר רב יותר של תמונות, סביר להניח כי נמצא תמונה יותר קרובה ויותר מייצגת, שכן לפי אלגוריתם ה- $NN - k$ , מרחק גיאומטרי קטן יותר אמור להניב חיזוי *label* טוב יותר, ועל כן, ככל ש- $n$  גדל, כך גדל גם אחוז הדיוק של האלגוריתם.